

Reconnaissance d'entités nommées patrimoniales pour Notre-Dame de Paris

Introduction

Le projet n-Dame Heritage est dédié à la construction d'un corpus numérique structuré de connaissances multidisciplinaires à partir de données textuelles hétérogènes (rapports, articles, compte rendus, etc.). L'implémentation de la reconnaissance d'entités nommées (NER ou REN) permettrait de rendre ces données textuelles interprétables et interconnectées, permettant de rendre compte de la réalité architecturale du chantier à travers le temps et les différents domaines concernés.

Cependant, les entités textuelles dans ces documents représentent des objets patrimoniaux complexes tels que des matériaux, des périodes historiques, des événements, des localisations précises... Notre objectif est de mettre au point un modèle d'annotation permettant de rendre compte précisément de ces complexités afin de les lier à des référents architecturaux et historiques.

Le corpus d'étude

Notre corpus est constitué de soixante-six articles multidisciplinaires en anglais et en français. Tous proviennent de HAL, et rapportent du chantier de Notre-Dame. De par la nature des textes qui le composent, le corpus pose quelques difficultés :

- Il présente des concepts qui sont propres au patrimoine, donc peu, mal ou non pris en charge par les modèles d'annotations pré-entraînés génériques.
- Les données (la longueur des articles, le nombre de chacun dans toutes les catégories, la répartition des langues) sont inégales.
- Certains concepts architecturaux peuvent être présents sous plusieurs dénominations. Les articles pouvant être écrits dans deux langues différentes, il sera nécessaire de relier les termes équivalents aux concepts correspondants. Également, dans une même langue, la terminologie peut différer selon la discipline concernée ou certaines abréviations spécifiques au domaine peuvent apparaître.


Quelques chiffres concernant le corpus :

- 64% des textes sont en anglais et 36% sont en français.
- Le corpus contient trente-quatre domaines répertoriés sur HAL. Certaines thématiques étant très similaires (Son-Acoustique, Mécanique des matériaux-Matériaux) sont rassemblées sous une même catégorie. Les documents possèdent régulièrement plusieurs thématiques.

Domaines des documents :

Son (+Acoustique)	Architecture (aménagement de l'espace)	Sciences de l'Homme et Société	Informatique	Sciences de l'information et communication
27	13	9	7	6


Archéologie et Préhistoire	Héritage culturel et muséologie	Modélisation et simulation	Matériaux (+Mécanique des Matériaux)	Architectures Matérielles
6	6	5	5	5
Vision par ordinateur et reconnaissance de formes	Musique, Musicologie et Arts de la Scène	Océan et atmosphère	Histoire	Santé publique et épidémiologie (+Santé)
3	3	3	3	2
Anthropologie sociale et ethnologie	Chimie analytique (+Chimie)	Interfaces continentales, environnement	Machine Learning	Art et histoire de l'art
2	2	2	2	2
Mécanique des Structures (+Structures)	Milieus et Changements Globaux	Environnement et Société	Planète et Univers	Synthèse d'image et réalité virtuelle
2	1	1	1	1
Génie mécanique	Sciences de l'environnement	Intelligence artificielle	Génie Civil	Sciences de l'ingénieur
1	1	1	1	1



- Le corpus contient neuf types de documents répertoriés sur HAL.

Types de documents :

Article dans une revue	Communication dans un Congrès	Poster de Conférence	Chapitre d'Ouvrage	Compte-rendu d'article
26	22	11	2	1
Rapport de Recherche	Proceedings/Recueil de communications	Thèse	Autre publication scientifique	Total : 66
1	1	1	1	



La prochaine étape

Une fois le corpus établi et prêt, la prochaine étape sera de le soumettre aux premiers outils d'annotation automatique : des modèles Transformer pré-entraînés sur des données générales, avec des étiquettes générales elles aussi (personne, organisation, lieu...). L'objectif est d'observer comment se comportent les modèles sans aucune modification spécifique aux données.

Plusieurs pistes de réflexion sont considérées pour le projet. Un prochain objectif serait d'aller au-delà de ces annotations standards pour intégrer des attributs spécifiques tels que des dates, des locations relatives, ou encore des relations temporelles. L'établissement des relations sera notamment possible grâce à des outils d'annotation, comme Brat.

Nous pensons qu'il serait judicieux d'intégrer des thésaurus d'architecture afin d'avoir une approche plus hybride de la reconnaissance d'entités nommées. En effet, le corpus contenant

des concepts spécifiques à un domaine, il est envisagé de lier nos entités à des réalités architecturales existantes correspondantes dans les lexiques. Cela permettrait un meilleur traitement des informations.

Bibliographie

Projets sur des thématiques similaires :

- NER4Archives : <https://www.archives-nationales.culture.gouv.fr/innovation-et-recherche/ner4archives-reconnaissance-dentites-nommees-pour-les-services-darchives>
- The Heritage Connector Project: <https://www.sciencemuseumgroup.org.uk/projects/heritage-connector>

Approche hybride pour la REN :

- Ferro, S., Giovanelli, R., Leeson, M. *et al.* “A novel NLP-driven approach for enriching artefact descriptions, provenance, and entities in cultural heritage.”, *Neural Comput & Applic* **37**, 21275–21296 (2025). <https://doi.org/10.1007/s00521-025-11449-2>
- Yan D., Lei M., Shi Y. (2025), “A hybrid approach to advanced NER techniques for AI-driven water and agricultural resource management”, *Front. Environ. Sci.* 13:1558317, doi: 10.3389/fenvs.2025.1558317

Réflexions sur les relations entre entités :

- Anaïs Guillem, Antoine Gros, Kévin Réby, Violette Abergel, Livio De Luca. RCC8 for CIDOC CRM: Semantic Modeling of Mereological and Topological Spatial Relations in Notre-Dame de Paris. *SWODCH'23 : International Workshop on Semantic Web and Ontology Design for Cultural Heritage*, Nov 2023, Athènes, Greece. hal-04275714v1
- ArCo – Architecture of Knowledge: <https://dati.beniculturali.it/arco/index.php?lang=en>

Thésaurus :

- Thésaurus *Frollo* du chantier scientifique de Notre-Dame de Paris (nDame) sur Opentheso : <https://frollo.notre-dame.science/index.xhtml>

Outils :

- Brat – rapid annotation tool : <https://brat.nlplab.org>
- SpaCy : Honnibal, M., Montani, I., Van Landeghem, S., Boyd, A. (2020). spaCy: Industrial-strength Natural Language Processing in Python. <https://spacy.io/>