

La reconnaissance d'entités nommées pour Notre Dame de Paris, premiers pas

Introduction

Cette première étape de réflexion s'ancre sur un état de l'art des modèles de NER disponibles, et qui ont été utilisés dans des projets culturels similaires (ayant pour thème la reconnaissance d'entités patrimoniales). De même, nous pensons qu'il sera nécessaire d'annoter manuellement certaines de nos données, et c'est pour cela que des outils d'annotations seront, eux aussi, synthétisés.

Modèles utilisés dans des projets similaires

Outil/Modèle	Type	Langues supportées
SpaCy	Transformer	Multilingue
SpaCy (RoBERTa)	Transformer	Multilingue
Flair	Transformer	Multilingue
DeLFT	Transformer	Multilingue
GLiNER	Transformer	Multilingue

Premières observations avec SpaCy

Après avoir analysé les résultats provenant de premiers essais SpaCy, quelques remarques émergent. La plupart des textes contenaient des problèmes de traitement et ce pour plusieurs raisons.

Bien souvent, des lettres manquaient dans des mots, faussant ainsi le traitement de ceux-ci. Après vérification, il s'avère que les polices d'écriture étaient souvent mal, ou non-reconnues. Dans l'exemple suivant : **effondré**, le mot "effondré" donne "éondré", car le double f n'est pas pris en compte (les caractères ne sont pas reconnus).

Un autre problème provient de la nature même de certains documents. En effet, onze des documents de notre corpus sont des posters de conférence. Cela signifie donc que le texte est, en général, plus petit, arrangé d'une manière différente d'un article classique, et contient beaucoup d'images. Celles-ci sont très mal traitées, et produisent des longues répétitions de lettres qui leur réfèrent (cicidcicidcicid... sur plusieurs lignes). Également, si les images contiennent du texte, aussi petit soit-il, il sera reconnu et mal traité, parasitant donc les résultats.

Au-delà des soucis liés au traitement, l'étiquetage des entités présente lui aussi ses problématiques. Les modèles de SpaCy dans leurs versions les plus génériques (*en_core_web_sm*, *en_core_web_md*, *en_core_web_lg* et *en_core_web_trf* pour l'anglais, et *fr_core_news_sm*, *fr_core_news_md* et *fr_core_news_lg* pour le français) ne proposent que très peu d'étiquettes qui sont réellement intéressantes pour ce que nous souhaitons obtenir des entités présentes dans notre corpus. Parmi les étiquettes préexistantes, nous ne trouvons aucune étiquette mentionnant les matériaux, les méthodes utilisées, ou bien les éléments architecturaux.

De plus, en gardant toutes les étiquettes proposées par ces modèles génériques, les entités sont classées en majorité dans la catégorie Cardinal (les nombres). Cette catégorie ne possédant pas d'importance sémantique pour notre projet, les chiffres et nombres seront supprimés lors du nettoyage, sauf quand ceux-ci correspondent à des dates.

Enfin, il est prévu d'essayer plusieurs outils d'annotations sur nos données. Afin de pouvoir travailler sur ces différents logiciels, il est nécessaire d'avoir un format plus commun que du .pdf, et donc une conversion des fichiers en .txt sera effectuée.

Pré-traitement des données et conversion

Avant de procéder à la conversion, nous commençons par le pré-traitement. La première étape consiste en l'effacement des images contenues dans les fichiers, car celles-ci ne nous intéressent pas et perturbent bien souvent le texte de sortie.

La première page de chacun des fichiers est extraite. Elle représente la page de garde, avec le titre du document, les auteurs, et la référence HAL du document. Ces informations ne sont pas nécessaires pour le travail sémantique qui sera réalisé par les prochaines étapes. De même, les bibliographies de chaque document seront enlevées. C'est à partir de l'étape du nettoyage que quelques difficultés émergent. Si tous nos fichiers proviennent du même site (HAL) et donc contiennent tous une page de garde non-utile à notre traitement, les structures des documents ne sont pas uniformes. La mise en page du corps du texte (une colonne, deux, trois...), la bibliographie, la taille de la police, ainsi que d'autres éléments sont très variables. Afin de cibler effectivement ces éléments, nous utilisons la librairie PyMuPDF, très efficace sur la détection de titres et de blocs de textes. Les documents seront ensuite séparés en deux catégories, afin de faciliter l'application de deux traitements différents. La première catégorie contient les articles organisés avec une seule colonne, le texte se lisant de la manière traditionnelle (gauche vers la droite, puis haut vers le bas). La deuxième contient quant à elle tous les documents organisés avec deux colonnes en plus. Dans leurs cas, le texte se lit différemment car on considère qu'il est divisé en autant de parties qu'il a de colonnes. Si un document a deux colonnes, il est nécessaire de d'abord traiter la colonne de gauche (de gauche à droite, du haut vers le bas), puis la colonne droite de la même manière.

Pour le nettoyage des articles, les éléments suivants sont retirés :

- La page de garde HAL,
- Les sections de fin (remerciements, copyright, informations supplémentaires, bibliographie, etc.),
- Les nombres entourés d'espaces qui ne sont pas composés de quatre chiffres (afin de ne garder que les années),
- Toutes les marques de ponctuation,
- Les liens internet,
- Les abréviations faisant référence à d'autres éléments dans le texte (fig, hal, cid, doi, col...),
- Les lettres seules,
- Les noms "génériques" de sections (introduction, conclusion).

La conversion des fichiers .pdf possédant plusieurs colonnes en données textuelles se fait, comme expliqué précédemment, par la lecture des colonnes les unes après les autres. Pour la majorité des fichiers à colonnes multiples, il suffit de "couper" la page à sa moitié en deux parties, et de lire chaque partie l'une après l'autre. Cependant, certains documents nécessitent un traitement plus particulier. Il est alors envisagé, de reconstruire l'ordre logique de lecture des différents blocs de texte. Pour cela, les blocs de texte sont d'abord détectés horizontalement,

de gauche à droite, puis rassemblés s'ils sont proches en localisation afin de former une colonne. Cela permet de traiter correctement les fichiers ayant trois colonnes ou plus, ou encore les fichiers ayant des colonnes non-alignées sur le milieu.

Une étape commune du pré-traitement de données textuelles consiste à enlever les stopwords, des mots vides qui à eux-mêmes n'apportent pas de valeur sémantique à un texte. Dans le cas de notre corpus, cette étape a été envisagée. Du fait de la nature des entités que nous comptons extraire, nous pensions que certains stopwords sont indispensables. Nous souhaitons par exemple extraire des entités patrimoniales et produire des annotations de relations sémantiques telles que des relations de localisation (Objet 1 est situé sous, au-dessus, sur, à droite... de l'Objet 2). La suppression des stopwords en utilisant une liste pré-faite constituerait alors une perte de contexte pourtant nécessaire à la future classification. Nous pourrions considérer cependant de créer une liste personnalisée à notre corpus, qui nous permettrait de supprimer les éléments inutiles (les pronoms) et de garder des éléments référant à la localisation et l'état des objets patrimoniaux. Pour évaluer si la suppression de stopwords est réellement efficace sur le traitement de nos données, une expérimentation peut être faite avec et sans stopwords plus tard lorsque les modèles seront utilisés sur nos données nettoyées.